

Contrastive Learning for Speech Enhancement

郭品辰
F14066127
NCKU SNAME

黃仁鴻
P76094169
NCKU CSIE




Figure 1. 語音增強使用的 Auto Encoder。期望模型能將受雜訊污染的語音還原成乾淨語音。

1. Introduction

許多與日常生活息息相關的任務都是仰賴語音作為資訊傳遞的媒介，像是電話通訊、語音辨識與助聽器等等。然而在現實環境中充滿著各種不可預期的噪音干擾，這嚴重影響了語音訊號技術的效能。因此，將這些雜訊去除的語音增強技術就成了對語音任務很重要的前置處理單元。

而語音增強的問題就是不論在何種噪音環境，面對相同的語音，模型都能夠抽取出相同的特徵，進而利用與特徵來重構語音。這部分想法與近年流行自監督方法中的對比學習 (Contrastive Learning) 不謀而合，對比學習希望相似樣本間的特徵編碼能越像越好，而不同樣本的特徵差異則是越大越好。

我們認為，藉由 CL 的方法來學習語音特徵的潛在編碼，再利用此特徵編碼還原語音，應該會具備比一般深度學習的語音增強方法更高的通用性與泛化能力。因此，對比學習應用於語音增強任務的可行性將會是本次專題的研究主軸。

然而，如同 SimCLR [1] 等等 CL 方法都需要使用到大量的負樣本輔助進行訓練，否則會發生 collapsing output 的問題，也就是不論輸入任何東西都只會有相同輸出。而大量的負樣本需求導致這些方法必須使用極大的 batch size 才能獲得良好效果，像是在 SimCLR 的論文中，實驗所使用的 batch size 就到達了 4096。

為了因應實驗環境的硬體限制，本專題將會基於 BYOL [4] 與 SimSiam [2] 這兩種且在小型 batch size 也有良好成效的 CL 方法進行實驗，並與監督式語音增強方法進行比較。

2. Related works

3. Method

本專題使用的模型結構如 Figure 1. 所示，是由 Encoder 與




Figure 2. BYOL 的算法架構。Encoder-PredictNet 會將 Encoder' 取出特徵做為目標，計算 L2 Loss 後更新 Encoder-PredictNet 的參數，Encoder' 則會把自身目前參數與更新後 Encoder 做加權平均當新參數。




Figure 3. SimSiam 的算法架構。將混合不同噪音的語音輸入 Encoder 得到 Z_1 與 Z_2 ，在將 Z_1 與 Z_2 輸入 PredictNet 後獲得 P_1 與 P_2 ， P_1 與 P_2 會各自將 Z_2 與 Z_1 做為目標並計算差距，以此更新 Encoder-PredictNet 的參數。

Decoder 兩區塊組合而成，其中負責抽取語音特徵 Encoder 區塊將會使用 BYOL 與 SimSiam 進行預訓練。在進行 CL 訓練時，語音 S 會混合 N_1 與 N_2 兩個不同的噪音後，輸入 Encoder 取出語音的特徵向量，並用 Figure 2. 與 Figure 3. 所

Table 1. 各模型的對噪聲語音進行去噪後的平均評估結果

Model	Evaluation Metrics		
	PESQ	STOI	SI-SNR
Noisy	1.813	0.764	0.001
Normal	2.273	0.814	7.146
BYOL	2.392	0.844	9.174
BYOL round	2.461	0.858	9.378
BYOL round(100 s)	2.474	0.861	9.526
SimSiam	2.374	0.84	8.884
SimSiam round	2.472	0.861	9.529

Table 2. 各模型的對混和不同 SNR 雜訊進行去噪後的 PESQ 評估結果

Model	-7.5	-2.5	2.5	7.5
	PESQ			
Noisy	1.337	1.644	1.971	2.3
Normal	1.826	2.138	2.438	2.688
BYOL	1.875	2.253	2.59	2.851
BYOL round	1.904	2.3	2.671	2.97
BYOL round(100 s)	1.913	2.308	2.683	2.991
SimSiam	1.873	2.24	2.563	2.82
SimSiam round	1.937	2.317	2.672	2.962

述的方法更新其內部權重¹。

在使用 CL 預訓練完 Encoder 後，便會將其串接上 Decoder，將乾淨的語音當成目標來進行語音增強任務的學習。更詳細的實驗內容在 Expected results 中。

4. Experiments

本專題使用的噪音資料集是由 20 種不同類型的背景噪音所組成，總共有 100 個音檔的 Nonspeech [5]。而語音資料集則是選用 TIMIT [3]，TIMIT 具有 6300 句語音，這些語音包含美國八個地區共 630 人所念出的 10 個指定句子。

在訓練時的噪聲語音是將 4120 句 TIMIT 語音與 75 個 Nonspeech 雜訊以 -10, -5, 0, 5, 10 這三種 SNR 混合產生的，其取樣頻率為 16K Hz，擷取時間約為 1s (16384 個樣本點)。測試則分別使用 500 與 25 個語音及噪音以 -7.5, -2.5, 2.5, 7.5 SNR 進行混合，並擷取約 2s (32768 個樣本點) 進行測試並計算其 PESQ[6]、STOI[8] 及 SISDR[7] 作為效能評估指標。

實驗中訓練的模型分別為使用 BYOL、SimSiam 以及未使用 CL 的 Normal 這三類，在 Fig.4 中展示 CL 方法與 Normal 的收斂差異，BYOL 與 SimSiam 在初期就以極快的速度提升效能。

5. Conclusion

本次將 Contrastive Learning 運用於 Speech Enhancement 的研究結果可發現，前期使用 CL Loss 對中間的隱藏特徵進行高強度的約束，能提升模型的收斂速度。然而若在中後期繼續讓 CL Loss 維持較高的權重反而會阻礙模型提升效能。但這並不代表 CL Loss 就完全不重要，相反的，保持一定程度的 CL 約束能有效避免 Overfitting 的發生。

未來將使用兩種以上的雜訊與語音進行混和，以驗證在更加複雜的資料擴增下使用 Contrastive Learning，能否讓

¹在 Figure 2. 與 Figure 3. 中的 X 符號代表 Stop Gradient，因此梯度並不會通過該區段向前更新。

Table 3. 各模型的對混和不同 SNR 雜訊進行去噪後的 STOI 評估結果

Model	-7.5	-2.5	2.5	7.5
	STOI			
Noisy	0.643	0.728	0.809	0.878
Normal	0.702	0.793	0.859	0.904
BYOL	0.734	0.826	0.889	0.928
BYOL round	0.746	0.841	0.904	0.942
BYOL round(100 s)	0.75	0.844	0.906	0.944
SimSiam	0.729	0.822	0.885	0.926
SimSiam round	0.753	0.845	0.905	0.942

Table 4. 各模型的對混和不同 SNR 雜訊進行去噪後的 SI-SDR 評估結果

Model	-7.5	-2.5	2.5	7.5
	SI-SDR			
Noisy	-7.497	-2.498	2.503	7.498
Normal	2.611	6.065	8.972	10.935
BYOL	3.677	7.785	11.281	13.951
BYOL round	3.396	7.772	11.615	14.728
BYOL round(100 s)	3.457	7.859	11.784	15.004
SimSiam	3.544	7.508	10.913	13.572
SimSiam round	3.583	7.935	11.751	14.847




Figure 4. 使用 BYOL、SimSiam 的模型與未使用 Contrastive Learning 方法的 Normal 進行比較。可以發現 Contrastive Learning 在前期可以快速的提升模型的效能。

Speech Enhancement 的效能有更大幅度的提升。並研究具有自適應性的 CL Loss 與 SE Loss 權重調整方法，好減少人工調整超參數的麻煩。

References

- [1] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey E. Hinton. A simple framework for contrastive learning of visual representations. *CoRR*, abs/2002.05709, 2020.
- [2] Xinlei Chen and Kaiming He. Exploring simple siamese representation learning. *CoRR*, abs/2011.10566, 2020.
- [3] J. S. Garofolo, L. F. Lamel, W. M. Fisher, J. G. Fiscus, D. S. Pallett, and N. L. Dahlgren. Darpa timit acoustic phonetic continuous speech corpus cdrom, 1993.




Figure 5. BYOL 與 SimSiam 的實驗結果。若在中後期減少 CL Loss 的約束力，反而能使模型效能提升更加迅速。但也可從 SimSiam pretrain 的實驗也觀察到，若完全移除 CL Loss 會導致模型發生 overfitting。

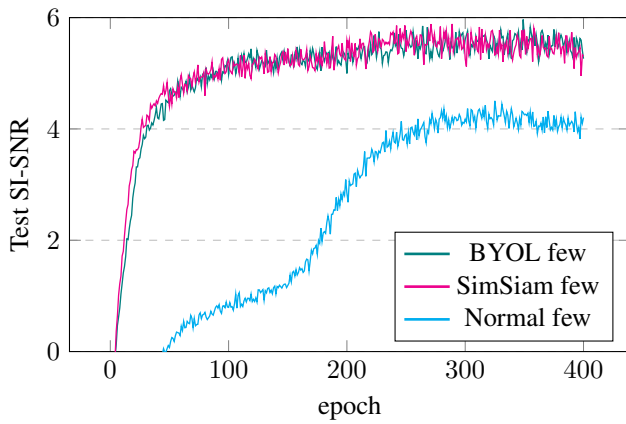


Figure 6. 改為使用測試集進行訓練、訓練集進行測試。即使是在只有少量資料的情況，Contrastive Learning 依然比只使用 Speech Enhancement Loss 的方法具有更高的效能。

- [4] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H. Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Ávila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko. Bootstrap your own latent: A new approach to self-supervised learning. *CoRR*, abs/2006.07733, 2020.
- [5] Guoning Hu and DeLiang Wang. A tandem algorithm for pitch estimation and voiced speech segregation. *IEEE Transactions on Audio, Speech, and Language Processing*, 18(8):2067–2079, 2010.
- [6] A.W. Rix, J.G. Beerends, M.P. Hollier, and A.P. Hekstra. Perceptual evaluation of speech quality (pesq)-a new method for speech quality assessment of telephone networks and codecs. In *2001 IEEE International Conference on Acoustics, Speech, and Signal Processing. Proceedings (Cat. No.01CH37221)*, volume 2, pages 749–752 vol.2, 2001.
- [7] Jonathan Le Roux, Scott Wisdom, Hakan Erdogan, and John R. Hershey. SDR - half-baked or well done? *CoRR*, abs/1811.02508, 2018.
- [8] Cees H. Taal, Richard C. Hendriks, Richard Heusdens, and Jesper Jensen. A short-time objective intelligibility measure for time-frequency weighted noisy speech. In *2010 IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 4214–4217, 2010.